

基于大模型先验与因果稳定约束的金属增材制造多模态缺陷识别方法

谷俊伟, 郭佳辉, 王宇

摘要—金属增材制造原位监测通常同时获取视觉与红外等多模态观测, 但当训练与测试工况不一致时, 模型容易将背景纹理、热场分布等工况相关线索误当作缺陷依据, 导致未见工况下的识别性能明显下降。针对这一问题, 本文提出多模态因果稳定 Qwen 网络 (MCSQ-Net, Multimodal Causal-Stable Qwen Network)。该方法以预训练大模型的视觉编码部分作为共享特征提取器, 通过多模态表征学习构建统一融合空间, 并在融合表示层对同标签异工况样本施加因果一致性约束, 以抑制工况诱导偏移; 随后采用轻量判别头完成缺陷类别识别, 从而在保留大模型泛化先验的同时实现小样本任务适配。实验在源域未见工况交叉验证和外部迁移测试两种设定下开展。结果表明, MCSQ-Net 在 Task-1 缺陷类别识别任务上取得 0.8547 的 Macro-F1 和 0.8556 的 Balanced Accuracy, 在 Task-3 外部迁移任务上取得 0.6067 的 Macro-F1, 均优于 Prompt-Qwen 和经典多模态基线。消融实验进一步表明, 因果一致性约束能够稳定提升跨工况表征质量, 而激进解冻视觉主干反而会削弱未见工况泛化能力。上述结果说明, 面向工业小样本多模态缺陷识别, 保留大模型视觉先验并在融合空间显式学习跨工况稳定表示, 是提升未见工况识别性能的有效途径。

Index Terms—选择性激光熔化, 缺陷识别, 多模态融合, 未见工况泛化, 外部迁移, 大模型先验, 因果稳定约束。

I. 引言

金属增材制造通过逐层熔化金属粉末构建复杂几何零件, 已广泛应用于航空航天、医疗器械和模具制造等领域。以选择性激光熔化 (Selective Laser Melting, SLM) 为例 [1]。该工艺成形涉及熔池动力学、热传导和凝固等复杂物理过程, 工艺参数的波动会直接导致气孔、裂纹和几何变形等缺陷 [2]。微小的工艺偏差即可显著影响零件的机械性能和服役可靠性。

工业系统通常部署可见光相机与红外热像仪同步监测金属增材制造过程 [3], [4]。可见光成像捕捉熔池形态和表面纹理, 红外热成像反映热输入分布和温度场演化。这种多模态观测提供互补的缺陷表征信息。然而, 现有监测方法大多假设训练数据与测试数据来自相

同分布。当工艺参数、设备型号或粉末批次变化时, 模型识别性能显著下降。

这一失效模式源于深度学习模型对虚假相关性 (spurious correlations) 的过度依赖。模型倾向于利用背景纹理、光照条件或设备噪声等表面统计特征进行预测, 而非缺陷本质的因果特征。在金属增材制造多模态监测中, 这意味着模型可能将特定工况下的热背景模式误识为缺陷依据, 导致在未见工况 (unseen condition) 下失效。如何实现训练工况到未见工况的稳定识别, 成为金属增材制造 (特别是 SLM) 缺陷识别的核心问题。

预训练视觉大模型为上述问题提供了可能的解决路径。这些模型通常在海量多模态数据上训练, 具备处理异构数据特征输入的能力; 其接触到的多样化视觉模式, 理论上应有助于提取跨工况稳定的特征。然而, 现有实验表明: 简单的提示工程 (prompt engineering) 方法在未见工况设定下性能不足。大模型的多模态先验并不能自动转化为对工业缺陷的准确识别, 关键在于如何设计适配机制, 使其在保持跨工况稳定性的同时, 有效融合多源传感器数据中的互补信息。

本文提出多模态因果稳定 Qwen 网络 (MCSQ-Net, Multimodal Causal-Stable Qwen Network), 用于未见工况下的金属增材制造缺陷识别。其核心思路是将预训练视觉大模型作为跨工况特征提取器, 通过显式多模态融合整合可见光与红外热信息, 并在融合空间中施加因果一致性约束。MCSQ-Net 采用轻量化的判别式适配机制, 在保留大模型预训练先验的同时, 学习跨工况不变的缺陷表征。具体而言, 因果稳定假设认为: 与工况相关的纹理、亮度和热背景特征会随工艺条件变化, 而缺陷本体的本质特征应当在跨工况时保持稳定。通过对同标签但来自不同工况的样本施加一致性约束, 模型被迫减少对不稳定环境因素的依赖, 从而学习到从训练工况到未见工况的稳健映射。

本文的主要贡献可概括为以下三方面:

- 1) 论证了多模态融合在未见工况缺陷识别中的必要性。通过对比单模态与多模态配置在跨工况场景下的性能差异,表明融合可见光与红外信息能够显著提升模型对未见设备、未见工艺参数的适应能力,为工业监测系统的传感器配置提供了实证依据。
- 2) 构建了大模型先验引导的未见工况缺陷识别框架。该框架采用轻量化判别式适配机制,在冻结预训练视觉主干的同时,通过可学习的多模态融合头实现特征整合,兼顾了部署效率与识别精度。实验表明,该框架在跨设备迁移场景中保持了稳定的缺陷检出率,具备较强的工程实用性。
- 3) 提出了因果稳定表征学习机制。通过对同标签但来自不同工况的样本施加一致性约束,迫使模型抑制对背景纹理、热噪声等环境因素的依赖,转而学习缺陷本体的本质特征。这一机制使模型能够从训练工况有效泛化到未见工况,为实现鲁棒的工业视觉监测提供了可行路径。

II. 相关工作

A. 金属增材制造中的多模态缺陷监测

金属增材制造原位监测已形成以可见光成像、红外热成像和多传感器融合为代表的三类技术路线 [1]–[4]。已有研究普遍表明,多模态观测能够从形貌、热输入和过程信号等不同侧面刻画缺陷形成过程,因此相比单一模态更有利于提高识别准确率。

围绕这一思路,Wu 等 [11] 证明了多传感器联合监测对质量等级识别的提升作用;Liu 等 [12] 通过声学与热辐射信号重建熔池视觉特征,以较低成本替代高速成像;Shen 等 [13] 进一步将红外图像、顶视图像、工艺参数和物理仿真结果联合建模;Li 等 [14] 则讨论了跨材料迁移条件下多模态特征的可迁移性。这些工作验证了多模态融合在缺陷监测中的有效性,但大多仍建立在训练域与测试域分布近似一致的前提下,对未见工况下由设备、工艺参数和环境变化共同引起的分布偏移关注不足。本文进一步讨论的是,在工况互斥划分下如何学习能够稳定迁移的多模态缺陷表征。

B. 大模型适配与跨域迁移

预训练大模型为工业异常检测和缺陷识别提供了新的先验来源。AnomalyGPT [5]、Myriad [6]、OmniAD [9] 和 AD-Copilot [10] 等工作分别从提示学习、专家模

型接入、监督微调和视觉上下文比较等角度展示了大模型在工业视觉任务中的应用潜力。与此同时,QLoRA、主动学习等轻量适配策略 [7], [8] 也表明,在资源受限场景下无需全参数微调即可完成任务特化。

不过,现有方法主要面向单数据集内的异常检测、定位或少样本适配,较少讨论金属增材制造场景中由模态异构和工况偏移共同导致的跨域泛化问题。尤其在训练工况与测试工况严格互斥时,仅依赖提示或常规微调难以保证模型真正学习到稳定的缺陷依据。与上述研究不同,本文将预训练大模型的视觉先验用于多模态统一编码,并在融合表示层引入跨工况因果一致性约束,从而显式提升未见工况下的缺陷识别稳定性。

III. 未见工况任务形式化

金属增材制造中的未见工况多模态缺陷识别可以定义为一个条件外推的监督分类问题。对样本 i , 记其联合观测为 $\mathbf{x}_i = \{\mathbf{x}_i^{(k)} \mid k \in \mathcal{M}_i\} \in \mathcal{X}$, 其中 $\mathcal{M}_i$ 表示可用模态集合,对于视觉与红外模态的观测样本, $\mathbf{x}_i^{(k)} \in \mathbb{R}^{H \times W \times C}$ 为第 k 个传感器输入, $y_i \in \mathcal{Y}$ 为缺陷标签, $c_i \in \mathcal{C}$ 为工况标识, $\mathcal{X}$ 表示多模态联合观测空间。工况变量 c_i 用于统一表征设备配置、工艺参数、打印任务和材料状态等会引起观测分布变化的外部因素。与常规同分布分类不同,训练集 $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_i, y_i, c_i)\}_{i=1}^N$ 与测试集 $\mathcal{D}_{\text{test}}$ 分别来自工况集合 $\mathcal{C}_{\text{train}}$ 和 $\mathcal{C}_{\text{test}}$, 并满足 $\mathcal{C}_{\text{train}} \cap \mathcal{C}_{\text{test}} = \emptyset$ 。因此,模型在测试阶段面对的不仅是新的样本实例,更是由设备、参数与任务条件整体变化所引起的系统性分布偏移。

在该设定下,模型需要仅基于 $\mathcal{D}_{\text{train}}$ 学习分类函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$, 并在未见工况上保持较低风险:

$$\mathcal{R}_{\text{uc}}(f) = \mathbb{E}_{(\mathbf{x}, y, c) \sim P_{\text{test}}} [\ell(f(\mathbf{x}), y)], \quad c \in \mathcal{C}_{\text{test}}, \quad (1)$$

其中, $\ell(\cdot, \cdot)$ 表示分类损失函数, $\mathcal{R}_{\text{uc}}$ 表示未见工况风险, P_{test} 表示测试阶段对应的数据分布。该目标之所以困难,在于多模态观测中同时混合了与缺陷形成机理相关的稳定判别因素,以及由工况变化诱导的背景统计和传感器响应差异。直接经验风险最小化 (ERM) 容易利用后者完成训练集拟合,从而将工况相关的表面相关性误写为决策依据,导致模型在 $\mathcal{C}_{\text{test}}$ 上失效。基于这一任务定义,后续方法将围绕异构观测统一表征、跨工况稳定特征提取和大模型先验迁移三个方面展开。




图 1. MCSQ-Net 整体框架。整体流程由共享视觉编码、多模态因果一致性融合和基于大模型泛化先验的轻量适配三部分构成

IV. 提出方法

针对未见工况下金属增材制造多模态缺陷识别中表征难统一、判别依据易随工况漂移且小样本外推能力不足的问题，本文提出 MCSQ-Net。对样本 i ，记其有效模态集合为 $\mathcal{M}_i = \{m_1, \dots, m_{K_i}\}$ ，其中 K_i 表示参与融合的模态数。MCSQ-Net 不将预训练大模型直接用于提示式闭集分类，而是将其视觉编码部分作为共享特征提取器，依次完成多模态表征学习、跨工况一致性融合和轻量判别适配，从而在尽量保留预训练先验的同时抑制工况诱导的表示漂移，学习跨工况稳定的缺陷判别表示。框架整体如图 1 所示。

A. 多模态特征提取

不同传感器的成像机制和统计分布并不一致。若为各模态分别训练独立编码器，模型容易在有限样本下记住工况相关纹理，而难以提取稳定的缺陷依据。为此，本文对所有输入模态共享同一个预训练大模型视觉编码主干 f_{θ_v} ，先将异构观测映射到统一语义空间，再在该空间内构造模态级表示。

对任意模态 $m \in \mathcal{M}_i$ ，设其输入观测为 $\mathbf{x}_i^{(m)}$ 。共享视觉编码主干输出该模态的空间特征序列

$$\mathbf{E}_i^{(m)} = f_{\theta_v}(\mathbf{x}_i^{(m)}) = \left[\mathbf{e}_{i,1}^{(m)}, \dots, \mathbf{e}_{i,P_i^{(m)}}^{(m)} \right]^\top \in \mathbb{R}^{P_i^{(m)} \times d_v}, \quad (2)$$

其中， d_v 表示特征维度， $P_i^{(m)}$ 表示该模态经视觉主干空间压缩后保留的局部特征数， $\mathbf{e}_{i,p}^{(m)}$ 表示第 p 个空间位置对应的局部视觉特征。由于后续融合需要定长输入，本文对空间特征序列执行均值池化，得到单模态表示

$$\mathbf{z}_i^{(m)} = \frac{1}{P_i^{(m)}} \sum_{p=1}^{P_i^{(m)}} \mathbf{e}_{i,p}^{(m)} \in \mathbb{R}^{d_v}. \quad (3)$$

式中， $\mathbf{z}_i^{(m)}$ 是模态 m 的全局语义向量。该操作将可变长度的空间序列压缩为定长向量，从而降低模态间融合的尺度差异。对样本 i 的全部输入模态，最终得到模态级特征组

$$\mathbf{Z}_i = \left[\mathbf{z}_i^{(m_1)}, \dots, \mathbf{z}_i^{(m_{K_i})} \right] \in \mathbb{R}^{K_i \times d_v}. \quad (4)$$

其中， K_i 表示样本实际参与融合的模态数。本文默认冻结共享视觉主干，仅将其作为统一特征提取器使用；这样既能保留预训练视觉先验，又能为后续跨工况一致性约束提供更稳定的表示基础。

B. 因果一致性表征融合

得到各模态的模态级向量后，若直接送入分类器，模型仍可能把亮度偏置、热场背景和纹理噪声一并编码为判别依据。因此，本节的目标不是构造更复杂的融合网络，而是在融合表示层显式约束跨工况稳定因素，使表征更集中于缺陷本身。




图 2. 多模态特征提取模块

具体而言, 先将样本 i 的多模态向量沿特征维拼接, 形成统一输入

$$\mathbf{g}_i = \text{Concat}(\mathbf{z}_i^{(m_1)}, \dots, \mathbf{z}_i^{(m_{K_i})}) \in \mathbb{R}^{K_i d_v}. \quad (5)$$

其中, $\mathbf{g}_i$ 表示不同模态观测的联合描述。为将其映射到可施加一致性约束的统一融合空间, 定义

$$\mathbf{h}_i = \phi_{\theta_f}(\text{LN}(\mathbf{g}_i)) \in \mathbb{R}^{d_h}. \quad (6)$$

其中, $\text{LN}(\cdot)$ 表示 LayerNorm, d_h 为融合空间维度。融合头 ϕ_{θ_f} 仅负责完成跨模态特征压缩与重组, 而对工况伪相关的抑制主要由后续一致性约束实现。

因果一致性约束建立在如下假设之上: 对于同一缺陷类别, 不同工况下的背景纹理、亮度分布和热场响应可以变化, 但决定类别归属的缺陷形态与异常热特征应保持稳定。为使这一稳定因素在融合空间中可约束, 本文首先对融合向量做 ℓ_2 归一化:

$$\bar{\mathbf{h}}_i = \frac{\mathbf{h}_i}{\|\mathbf{h}_i\|_2} \in \mathcal{S}^{d_h-1}. \quad (7)$$

归一化后的 $\bar{\mathbf{h}}_i$ 仅保留方向信息, 因此后续内积可直接刻画余弦相似度, 更适合衡量不同工况下缺陷语义的一致程度。

在此基础上, 为每个样本构造同标签异工况的参照对象。对样本 i , 定义其跨工况正样本池为

$$\Omega_i = \{j \mid j \neq i, y_j = y_i, c_j \neq c_i\}. \quad (8)$$

其中, $y_j = y_i$ 保证两者属于同一缺陷类别, $c_j \neq c_i$ 保证二者来自不同工况。这样得到的约束对象是样本级跨工况正样本对, 而非不同模态之间的直接对齐。若某个样本不存在可用正样本, 则该样本在当前 batch 中不参与一致性损失计算。




图 3. 因果一致性融合模块

对于当前批量 $\mathcal{B}$ 中具有有效正样本的锚点集合 $\mathcal{B}^+ = \{i \in \mathcal{B} \mid \Omega_i \neq \emptyset\}$, 从 Ω_i 中选取一个正样本 $\pi(i)$, 定义因果一致性损失为

$$\mathcal{L}_{cc} = \frac{1}{|\mathcal{B}^+|} \sum_{i \in \mathcal{B}^+} \left(1 - \bar{\mathbf{h}}_i^\top \text{sg}(\bar{\mathbf{h}}_{\pi(i)})\right), \quad (9)$$

其中, $\text{sg}(\cdot)$ 表示梯度停止算子, 用于阻断参照分支的梯度回传。由于 $\bar{\mathbf{h}}_i$ 和 $\bar{\mathbf{h}}_{\pi(i)}$ 已归一化, 二者内积直接对应余弦相似度。因此, 式 (9) 的作用就是拉近同标签异工况样本的融合表示, 使一致的缺陷语义在不同工况下保持接近, 并削弱工况差异对判别边界的干扰。

C. 基于大模型泛化先验的轻量适配

在得到融合表示后, 仍需将预训练大模型在开放域视觉数据上形成的泛化先验转化为具体的缺陷类别判别能力。若直接对视觉主干进行端到端微调, 有限样本容易将这一先验改写为少量工况样本上的局部经验; 若完全不做任务适配, 融合表示又难以形成稳定的类别边界。因此, 本文在冻结视觉主干的前提下, 仅更新融合头与分类头, 以较小参数代价完成任务适配。

具体地, 利用上一节得到的融合向量 $\mathbf{h}_i$ 计算分类得分向量

$$\ell_i = \mathbf{W}_c \mathbf{h}_i + \mathbf{b}_c \in \mathbb{R}^{|\mathcal{Y}|}, \quad (10)$$

其中, $\mathbf{W}_c \in \mathbb{R}^{|\mathcal{Y}| \times d_h}$ 和 $\mathbf{b}_c \in \mathbb{R}^{|\mathcal{Y}|}$ 分别表示分类头的权重矩阵与偏置向量, $|\mathcal{Y}|$ 表示缺陷识别任务中的类别数, $\ell_{i,k}$ 表示样本 i 指向第 k 类的未归一化判别得分。分类损失采用标准交叉熵形式

$$\mathcal{L}_{cls} = -\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \log \frac{\exp(\ell_{i,y_i})}{\sum_{k=1}^{|\mathcal{Y}|} \exp(\ell_{i,k})}, \quad (11)$$

其中, $|\mathcal{B}|$ 表示 batch 大小。 $\mathcal{L}_{cls}$ 负责学习缺陷类别边界, 而上一节的 $\mathcal{L}_{cc}$ 负责抑制工况诱导的表示漂移, 二者分别对应类别可分性与跨工况稳定性两个目标。

表 I
MCSQ-Net 训练流程伪代码

训练流程

```

1: 输入: 训练集  $\mathcal{D}_{\text{train}}$ , 验证集  $\mathcal{D}_{\text{val}}$ , 共享视觉主干  $f_{\theta_v}$ , 融合头  $\phi_{\theta_f}$ ,
   分类头  $(\mathbf{W}_c, \mathbf{b}_c)$ , 权重系数  $\lambda$ 
2: 初始化: 冻结  $f_{\theta_v}$  的全部视觉层; 根据标签和 condition_uid 为训练
   样本建立同标签异工况正样本池
3: for epoch = 1 to  $E$  do
4:   for mini-batch  $\mathcal{B}$  do
5:     按当前模式组合读取每个样本的输入观测, 并送入共享视觉主干
6:     对每个模式的空间特征序列做均值池化, 得到模式级向量  $\mathbf{z}_i^{(m)}$ 
7:     拼接所有模式向量, 经融合头得到  $\mathbf{h}_i$  及其归一化表示  $\bar{\mathbf{h}}_i$ 
8:     由分类头计算分类得分, 并得到分类损失  $\mathcal{L}_{\text{cls}}$ 
9:     if batch 中存在有效正样本对 then
10:      依据同标签异工况匹配关系计算一致性损失  $\mathcal{L}_{\text{cc}}$ 
11:     else
12:      令  $\mathcal{L}_{\text{cc}} \leftarrow 0$ 
13:     end if
14:     计算总损失  $\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{cc}}$ 
15:     反向传播并更新可训练参数
16:   end for
17:   在验证集上评估当前模型, 并按主指标保存最优 checkpoint
18:   if 连续若干 epoch 未提升 then
19:     触发 early stopping
20:   end if
21: end for
22: 输出: 验证集最优的模型参数及其测试集评估结果

```

在参数更新策略上, 本文冻结预训练视觉编码主干, 仅更新融合头参数 θ_f 与分类头参数 $\theta_c = (\mathbf{W}_c, \mathbf{b}_c)$ 。这种轻量适配方式将任务相关更新限制在小规模新增模块中, 从而在有限标注条件下尽量保留大模型的泛化先验。

综合以上设计, 模型的最终优化目标写为

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{cc}}, \quad (12)$$

其中, λ 为一致性约束权重。式 (12) 表明, 模型优化不仅要求训练集上的类别可分性, 还要求融合表示在工况变化下保持稳定。

D. 训练流程与整体架构

训练阶段采用标准 mini-batch 梯度下降。每一轮更新依次经过共享视觉编码、多模态融合、跨工况一致性对齐和判别优化四个步骤: 先由共享视觉主干提取模式级向量, 再由融合头得到 $\mathbf{h}_i$ 和 $\bar{\mathbf{h}}_i$, 随后联合计算 $\mathcal{L}_{\text{cls}}$ 与 $\mathcal{L}_{\text{cc}}$ 并更新可训练参数。表 I 给出了训练流程伪代码, 表 II 汇总了关键结构配置; 具体训练超参数放在实验设置中说明。




图 4. 开放式 SLM 原位监测实验平台与多传感器数据采集系统占位图。定稿时将在该展示激光加工单元、控制系统以及双视觉-红外监测阵列。

V. 实验与分析

A. 实验设置

实验数据来源于自主搭建的开放式选择性激光熔化原位监测平台, 如图 4 所示。平台采用 500 W 单模连续光纤激光器、振镜扫描系统和 PBAM 可编程控制软件, 可对激光功率、扫描速度等关键工艺参数进行实时调整; 成形过程在高纯氩气保护下进行, 氧气体积分数控制在 0.1% 以下。为采集多模态过程信号, 平台配置两台 KM2010-3660 工业相机和一台 Optris PI 08M 短波红外热像仪, 分别记录俯视/侧视可见光图像及垂直红外热场, 并通过 TTL 外部触发实现帧级同步。基于该平台构建的数据集包含视觉模态、红外模态及对应工况信息, 用于后续未见工况识别评估。

主方法采用 Qwen2-VL-2B-Instruct 的视觉编码主干, 融合空间维度设为 512, dropout 为 0.1, batch size 为 4, 优化器为 AdamW, 学习率为 3×10^{-4} , weight decay 为 10^{-4} , 并使用 cosine 调度、混合精度训练与 patience 为 2 的 early stopping。在输入形式上, 主方法比较了视觉模态、红外模态及其组合的识别效果, 主实验采用性能最优的输入配置。实验中记录的工艺参数用于划分不同工况并构造同标签异工况正样本; 类别标签仅作为监督信号参与训练, 而不作为推理阶段的输入。因果稳定约束权重取 0.1。真微调对照实验使用 batch size 1、3 个 epoch、patience 为 1, 视觉侧学习率为 2×10^{-6} , 融合头学习率为 5×10^{-5} , 梯度裁剪阈值为 0.5。最强经典基线为 ResNet18 + 双视觉输入 + MLP-concat。所有源域结果均在 3 个折上汇总, 实验任务设置如表 III 所示。

表 II
MCSQ-Net 的关键模型结构配置

模块	结构	作用
共享视觉主干	预训练视觉编码器, $d_v = 1536$, 冻结全部视觉层	提取统一模态特征
模态级聚合	均值池化, $\mathbf{z}_i^{(m)} \in \mathbb{R}^{d_v}$	生成模态级表示
特征拼接	$\mathbf{g}_i = \text{Concat}(\mathbf{z}_i^{(m_1)}, \dots, \mathbf{z}_i^{(m_{K_i})}) \in \mathbb{R}^{K_i d_v}$	保留模态互补信息
融合头	LN+Linear($K_i d_v, 512$)+GELU+Dropout(0.1)+Linear(512, 512)+GELU	压缩并重组融合特征
一致性约束	同标签异工况配对, 余弦一致性损失, $\lambda = 0.1$	抑制工况诱导偏移
分类头	Linear(512, $ \mathcal{Y} $)	输出缺陷类别得分
轻量适配	冻结视觉主干, 仅训练 $\{\theta_f, \theta_c\}$	保留大模型泛化先验

表 III
实验任务设置

编号	任务名称	任务设置
Task-1	源域未见工况缺陷类别识别	工况划分三折交叉验证; 训练、验证与测试工况互斥; 标签为健康 (normal)、高功率翘曲 (HEW) 和低功率异常未熔合 (LEL); 评估未见工况下的缺陷类别识别能力。
Task-2	源域未见工况异常识别	沿用 Task-1 的工况划分; 健康 (normal) 与缺陷 (abnormal) 二分类; 作为具有开集识别含义的补充任务, 用于评估模型对异常模式的分离能力。
Task-3	外部迁移缺陷类别识别	以 Task-1 源域训练集为基础, 在独立外部测试集上评估; 测试集不参与模型选择; 同时存在设备、工艺参数与缺陷分布偏移; 评估复合分布偏移下的类别识别稳定性。

本文统一报告 Accuracy、Balanced Accuracy 和 Macro-F1 三项指标。其中, Balanced Accuracy 与 Macro-F1 分别反映类别召回的均衡性和跨类别识别的整体稳定性。考虑到未见工况识别同时面临类别不均衡与类别间性能波动, 后文分析以这两项指标为主。

为便于结果呈现, 本文对主要对照组采用如下简称:

- C1: ResNet18 + Camera 1, 用于表征单视觉模态基线性能。
- IR-Only: ResNet18 + IR only, 用于评估红外热信息单独参与识别时的判别能力。
- Dual: ResNet18 + Camera 1 & 2 + MLP-concat, 用于评估双视觉模态下的显式特征拼接效果, 也是当前经典 CNN 路线中的最优配置。
- Tri-MLP: ResNet18 + Camera 1 & 2 + IR + MLP-concat, 用于考察三模态条件下的直接特征拼接效果。
- Tri-CA: ResNet18 + Camera 1 & 2 + IR + Cross-Attention, 用于考察三模态条件下的显式跨模态交互效果。
- Tri-LF: ResNet18 + Camera 1 & 2 + IR + Late Fusion, 用于考察决策层融合策略在三模态条件下的表现。
- Prompt-Qwen: 基于大模型先验的多模态提示分

类基线, 以 Camera 1、Camera 2 和 IR 的联合输入直接完成闭集识别。

- MCSQ-Net: 本文提出的方法, 同样以 Camera 1、Camera 2 和 IR 作为联合输入, 但在融合表征空间中进一步引入跨工况因果稳定约束。

B. 未见工况下的缺陷识别

表 IV 给出了源域未见工况缺陷类别识别结果。经典 CNN 路线中, ‘C1’ 已取得 0.8269 的 Macro-F1, 而双视觉拼接基线 ‘Dual’ 进一步提升至 0.8323, 说明互补视角能够改善缺陷判别; 但 ‘Tri-MLP’、‘Tri-CA’ 和 ‘Tri-LF’ 并未稳定超过 ‘Dual’, 表明单纯增加模态数或提升融合复杂度并不能自然带来跨工况增益。采用同样三模态输入的两条大模型路线则明显分化: Prompt-Qwen 的 Macro-F1 仅为 0.3914, 而 MCSQ-Net 提升至 0.8547, 并同时取得最高的 Accuracy 和 Balanced Accuracy。结合表中的可训练参数量可见, 这一优势并非来自更大的任务适配规模, 而是来自在保留大模型视觉先验的基础上, 通过同标签异工况表征对齐抑制工况诱导偏移, 从而获得更稳定的缺陷语义表示。

Task-2 的结果如图 5 所示。无论在 Balanced Accuracy 还是 Macro-F1 上, 最佳经典基线 ‘Dual’ 均明显优于 Prompt-Qwen 和 MCSQ-Net, 说明在当前设定下, 具有开集含义的异常识别仍更依赖显式判别式

表 IV
Task-1 未见工况缺陷类别识别结果

具体设置	Accuracy	Bal. Acc.	Macro-F1	可训练参数量	相对推理代价
C1	0.8237 ± 0.0440	0.8348 ± 0.0429	0.8269 ± 0.0483	11.18M	低
IR-Only	0.7271 ± 0.1127	0.7298 ± 0.1160	0.7117 ± 0.1254	11.18M	低
Tri-MLP	0.8138 ± 0.1127	0.8135 ± 0.1131	0.8106 ± 0.1143	12.23M	中
Tri-CA	0.8098 ± 0.0082	0.8198 ± 0.0117	0.8134 ± 0.0101	11.84M	中
Dual	0.8349 ± 0.0858	0.8412 ± 0.0846	0.8323 ± 0.0892	11.97M	低
Tri-LF	0.7747 ± 0.0503	0.7786 ± 0.0531	0.7751 ± 0.0522	11.31M	中
Prompt-Qwen	0.4809 ± 0.0602	0.5021 ± 0.0460	0.3914 ± 0.0587	$\approx 18.46\text{M}$	高
MCSQ-Net	0.8521 ± 0.0929	0.8556 ± 0.0973	0.8547 ± 0.0955	$\approx 1.84\text{M}$	较高

注：表中参数量为可训练参数量。经典 CNN 对照按 ResNet18 主干及对应融合头统计；Prompt-Qwen 按默认 LoRA 设定 ($r = 16, \alpha = 32$) 估算；MCSQ-Net 按主实验结果对应的双视觉配置统计。相对推理代价综合考虑编码主干规模、输入模态数及是否需要自回归解码。




图 5. Task-2 源域未见工况异常识别结果。图中比较了 Prompt-Qwen、最佳经典基线 ‘Dual’ 与 MCSQ-Net 在 Balanced Accuracy 和 Macro-F1 上的表现，误差棒表示 3 折标准差。

表征学习。与此同时，MCSQ-Net 在两项指标上仍高于 Prompt-Qwen，表明因果一致性约束能够在一定程度上改善异常模式的分离质量。因而，Task-2 主要作为补充评估，用于考察模型对异常与正常样本的区分能力。

Task-3 进一步检验了模型在外部迁移场景下的稳健性。该任务同时引入设备成像条件、工艺参数范围和缺陷分布的复合偏移，因此更容易放大模型对工况相关表面线索的依赖。图 6 给出了三种代表性方法从 Task-1 到 Task-3 的性能迁移轨迹。Prompt-Qwen 在源域与外部域上均保持较低水平；经典最优迁移基线 ‘Tri-LF’ 的 Macro-F1 由 0.7751 降至 0.4236，Balanced Accuracy 由 0.7786 降至 0.4973。相比之下，MCSQ-Net 在 Task-3 上仍取得 0.6067 的 Macro-F1 和 0.6359 的 Balanced Accuracy，且跨域退化幅度更小，表明因果一致性约束能够削弱工况相关伪线索对融合表示的干扰。

这一结果也补充说明了红外模态的作用方式。红外信息在增材制造监测中仍具有明确的物理意义和统计价值 [3], [4]，但其收益取决于融合机制和样本规模：在




图 6. Task-3 外部迁移缺陷类别识别结果及跨域性能退化。上：Macro-F1；下：Balanced Accuracy。每条轨迹连接 Task-1 源域未见工况结果与 Task-3 外部迁移结果，误差棒表示 3 折标准差，阴影区域表示外部目标域。

经典迁移基线中，‘Tri-LF’ 受益于三模态晚期融合；而在当前 MCSQ-Net 设定下，最优输入配置仍为 Camera 1 & 2。

C. 消融实验

为分析 MCSQ-Net 的性能来源，本节从多模态组合和方法组成两个方面开展消融。表 V 汇总了两类结果。多模态消融表明，各模态均能提供有效缺陷信息，但其收益取决于具体融合方式：IR 单模态仍可达

表 V
MCSQ-NET 消融结果

消融类别	具体设置	Balanced Accuracy	Macro-F1
多模态消融	Camera 1	0.7714 ± 0.0771	0.7419 ± 0.1203
	IR	0.6508 ± 0.0708	0.6270 ± 0.0878
	Camera 1 & 2	0.8422 ± 0.1061	0.8402 ± 0.1048
	Camera 1 & 2 + IR	0.8169 ± 0.0659	0.8121 ± 0.0615
	Camera 1 & 2 + 因果稳定约束	0.8556 ± 0.0973	0.8547 ± 0.0955
模型结构消融	w/o 因果稳定约束	0.8422 ± 0.1061	0.8402 ± 0.1048
	完整模型	0.8556 ± 0.0973	0.8547 ± 0.0955
	解冻最后两个视觉块	0.7979 ± 0.0332	0.7781 ± 0.0411

到 0.6270 的 Macro-F1，说明红外热信息具有独立判别价值；Camera 1 & 2 是当前最稳定的输入配置，表明双视角几何与纹理互补更适合当前任务；Camera 1 & 2 + IR 未超过 Camera 1 & 2，则说明当前瓶颈不在于是否引入红外模态，而在于如何更有效地建模其热特征贡献。这一判断与迁移基线的表现一致：在 Task-3 上，经典最优方法采用了三模态晚期融合，说明 IR 的最佳利用方式与模型家族密切相关。模型消融进一步验证了因果一致性约束的作用。去除该约束后，Macro-F1 和 Balanced Accuracy 分别由 0.8547 和 0.8556 降至 0.8402 和 0.8422；若解冻最后两个视觉块，Macro-F1 进一步降至 0.7781，且 Task-3 上也由 0.6067 降至 0.5808。这表明更有效的策略并非激进微调视觉主干，而是在保留大模型先验的基础上提升融合表示的稳定性。

VI. 结论

本文研究了金属增材制造未见工况下的多模态缺陷识别问题，重点关注如何利用预训练大模型先验提升跨工况稳定性。为此，本文提出 MCSQ-Net，通过共享视觉编码、多模态融合和跨工况因果一致性约束学习稳定的缺陷表示。实验表明，该方法在源域未见工况缺陷类别识别和外部迁移测试中均优于 Prompt-Qwen 与经典多模态基线，说明仅依赖提示或常规融合难以充分应对工况偏移，而在融合表示层显式抑制工况相关伪线索是提升泛化能力的关键。方法消融进一步表明，因果一致性约束能够稳定改善表示质量，而激进解冻视觉主干会削弱大模型原有先验并带来过拟合。后续工作可进一步探索面向红外热特征的更细粒度融合机制，以及视觉侧 adapter/LoRA 等更温和的参数高效适配方案。

参考文献

- [1] B. Zhang, Y. Li, and Q. Bai, "Defect formation mechanisms in selective laser melting: A review," *Chinese Journal of Mechanical Engineering*, vol. 30, pp. 515–527, 2017.
- [2] X. Peng, L. Kong, H. An, and G. Dong, "A review of in situ defect detection and monitoring technologies in selective laser melting," *3D Printing and Additive Manufacturing*, vol. 10, no. 3, pp. 438–466, 2023.
- [3] D. Guillen, S. Wahlquist, and A. Ali, "Critical review of LPBF metal print defects detection: Roles of selective sensing technology," *Applied Sciences*, vol. 14, no. 15, p. 6718, 2024.
- [4] P. Wang *et al.*, "Towards intelligent defect detection in metal powder bed fusion: A review of in situ monitoring, data pre-processing, and machine learning," *Materials Science and Engineering: R: Reports*, vol. 167, p. 101112, 2026.
- [5] Z. Gu *et al.*, "AnomalyGPT: Detecting industrial anomalies using large vision-language models," arXiv:2308.15366, 2023.
- [6] Y. Li *et al.*, "Myriad: Large multimodal model by applying vision experts for industrial anomaly detection," arXiv:2310.19070, 2023.
- [7] S. Chen and Y. Liu, "Vision-language model-assisted active learning for high-accuracy defect detection in automotive bushing components," in *Proc. Int. Conf. Embodied Intelligence and Large Models*, 2025, pp. 9–14.
- [8] H. V. Nguyen, H. Park, N. Yoo, and J. Yang, "Resource-efficient fine-tuning of large vision-language models for multimodal perception in autonomous excavators," *Frontiers in Artificial Intelligence*, vol. 8, p. 1681277, 2025.
- [9] S. Zhao *et al.*, "OmniAD: Detect and understand industrial anomaly via multimodal reasoning," arXiv:2505.22039, 2025.
- [10] X. Jiang *et al.*, "AD-Copilot: A vision-language assistant for industrial anomaly detection via visual in-context comparison," arXiv:2603.13779, 2026.
- [11] Q. Wu *et al.*, "In-situ quality intelligent classification of additively manufactured parts using a multi-sensor fusion based melt pool monitoring system," *Additive Manufacturing Frontiers*, vol. 3, no. 3, p. 200153, 2024.
- [12] H. Liu *et al.*, "Inference of highly time-resolved melt pool visual characteristics and spatially-dependent lack-of-fusion defects in laser powder bed fusion using acoustic and thermal emission data," *Additive Manufacturing*, vol. 83, p. 104057, 2024.
- [13] T. Shen *et al.*, "Multi-source information fusion for enhanced in-process quality monitoring of laser powder bed fusion additive manufacturing," *Additive Manufacturing*, vol. 96, p. 104575, 2024.
- [14] J. Li *et al.*, "Transfer learning-based quality monitoring of laser powder bed fusion across materials," *Expert Systems with Applications*, vol. 252, p. 124150, 2024.