

基于大模型先验与因果稳定约束的 SLM 多模态缺陷识别方法

作者姓名

摘要—选择性激光熔化 (Selective Laser Melting, SLM) 在线监测通常同时提供双视角可见光图像与红外热图,但在小样本和未见工况条件下,缺陷识别模型容易依赖工况纹理、热场背景等非稳定捷径特征,导致泛化性能显著下降。本文基于现有代码仓库,建立了以 `condition_uid` 为划分单元的 `data1 official_cv` 条件级主协议,并将 `data2 transfer_test` 视为包含未见模型和未见工艺的外部迁移压力测试。围绕该设定,本文关注的核心问题是:如何在 SLM 多模态缺陷识别中有效使用大模型先验,并在未见工况下保持稳定识别能力。实验表明,直接采用 Qwen2-VL 进行 prompt 式闭集分类效果有限,在 `data1 official_cv` 三分类上的 Macro-F1 仅为 0.3914。为此,本文提出一种基于 Qwen2-VL 视觉编码器、显式多模态融合头与因果稳定约束的大模型适配框架。该方法将 Qwen2-VL 作为预训练视觉先验,在融合表示空间中对同标签异工况样本施加一致性约束,并以轻量判别头完成小样本适配。实验结果表明,所提方法在 `data1 official_cv` 上取得 0.8547 的 Macro-F1 和 0.8556 的 balanced accuracy,在 `data2 transfer_test` 上取得 0.6067 的 Macro-F1,均优于 prompt-Qwen 和最强经典基线。输入消融进一步说明,RGB view 1、RGB view 2 与 IR 均提供有效缺陷线索,只是当前 Qwen 分支最优实现仍为双 RGB。进一步的真微调实验表明,直接解冻最后两个视觉 block 会导致性能退化,说明在当前小样本工业场景中,保留大模型先验并引入因果稳定约束,比激进端到端微调更有利于未见工况下的鲁棒识别。

Index Terms—选择性激光熔化,缺陷识别,多模态融合,未见工况泛化,外部迁移,大模型先验,因果稳定约束。

I. 引言

选择性激光熔化 (Selective Laser Melting, SLM) 通过逐层熔化金属粉末构建复杂几何零件,已广泛应用于航空航天、医疗器械和模具制造等领域 [1]。SLM 成形涉及熔池动力学、热传导和凝固等复杂物理过程,工艺参数的波动会直接导致气孔、裂纹和几何变形等缺陷 [2]。微小的工艺偏差即可显著影响零件的机械性能和服役可靠性。

工业系统通常部署可见光相机与红外热像仪同步监测 SLM 过程 [3], [4]。可见光成像捕捉熔池形态和表

面纹理,红外热成像反映热输入分布和温度场演化。这种多模态观测提供互补的缺陷表征信息。然而,现有监测方法大多假设训练数据与测试数据来自相同分布:当工艺参数、设备型号或粉末批次变化时,模型识别性能显著下降。

这一失效模式源于深度学习模型对虚假相关性 (spurious correlations) 的过度依赖。模型倾向于利用背景纹理、光照条件或设备噪声等表面统计特征进行预测,而非缺陷本质的因果特征。在 SLM 多模态监测中,这意味着模型可能将特定工况下的热背景模式误识为缺陷依据,导致在未见工况 (unseen condition) 下失效。如何实现训练工况到未见工况的稳定识别,成为 SLM 缺陷识别的核心问题。

预训练视觉大模型为上述问题提供了可能的解决路径。这些模型通常在海量多模态数据上训练,具备处理异构数据特征输入的能力;其接触到的多样化视觉模式,理论上应有助于提取跨工况稳定的特征。然而,现有实验表明:简单的提示工程 (prompt engineering) 方法在未见工况设定下性能不足。大模型的多模态先验并不能自动转化为对工业缺陷的准确识别,关键在于如何设计适配机制,使其在保持跨工况稳定性的同时,有效融合多源传感器数据中的互补信息。

本文提出一种基于大模型先验与因果稳定约束的未见工况缺陷识别方法。核心思路是将预训练视觉大模型作为跨工况特征提取器,通过显式多模态融合整合可见光与红外热信息,并在融合空间中施加因果一致性约束。该方法采用轻量化的判别式适配机制,在保留大模型预训练先验的同时,学习跨工况不变的缺陷表征。具体而言,"因果稳定"假设认为:与工况相关的纹理、亮度和热背景特征会随工艺条件变化,而缺陷本体的本质特征应当在跨工况时保持稳定。通过对同标签但来自不同工况的样本施加一致性约束,模型被迫减少对不稳定环境因素的依赖,从而学习到从训练工况到未见工况的

稳健映射。

本文的主要贡献可概括为以下三方面：

- 1) 论证了多模态融合在未见工况缺陷识别中的必要性。通过对比单模态与多模态配置在跨工况场景下的性能差异，表明融合可见光与红外信息能够显著提升模型对未见设备、未见工艺参数的适应能力，为工业监测系统的传感器配置提供了实证依据。
- 2) 构建了大模型先验引导的未见工况缺陷识别框架。该框架采用轻量化判别式适配机制，在冻结预训练视觉主干的同时，通过可学习的多模态融合头实现特征整合，兼顾了部署效率与识别精度。实验表明，该框架在跨设备迁移场景中保持了稳定的缺陷检出率，具备较强的工程实用性。
- 3) 提出了因果稳定表征学习机制。通过对同标签但来自不同工况的样本施加一致性约束，迫使模型抑制对背景纹理、热噪声等环境因素的依赖，转而学习缺陷本体的本质特征。这一机制使模型能够从训练工况有效泛化到未见工况，为实现鲁棒的工业视觉监测提供了可行路径。

II. 相关工作

A. 金属增材制造中的多模态缺陷监测

金属增材制造过程的在线监测对于确保成形质量至关重要。Zhang 等 [1] 系统综述了选择性激光熔化中的缺陷形成机制，指出工艺参数波动与缺陷产生之间存在密切关联。Peng 等 [2] 进一步总结了缺陷检测与监测技术的最新进展。现有研究主要从三个技术路线开展：基于可见光成像的形貌分析、基于红外热成像的温度场监测，以及多传感器数据融合方法 [3], [4]。

多传感器融合已成为提升监测精度的有效途径。Wu 等 [11] 采用高速相机、光电二极管和麦克风三种模态对 LPBF 熔池过程进行实时监测，通过改进的 LeNet-5 和加权 Dempster-Shafer 证据理论进行单传感器、双传感器和三传感器融合对比，结果表明三传感器融合对质量等级的识别准确率显著提升。这一工作验证了多模态信息互补在缺陷识别中的必要性。

针对高成本视觉传感器的部署限制，研究者探索了低成本多模态替代方案。Liu 等 [12] 利用声发射和热辐射信号推断高时间分辨率的熔池视觉特征，并识别空间相关的未熔合缺陷，实现了在 1.0 ms 时间窗内的熔池动态监测。该方法将难以集成的昂贵高速成像替换为更

易部署的声学-热辐射组合，为工业现场的传感器配置提供了可行方案。

进一步地，多源信息融合开始超越单纯的传感器堆叠。Shen 等 [13] 将逐层熔池红外图像、熔道顶视照片、数值模拟图、工艺参数和熔池截面形貌特征参数共同输入模型，提出残差物理融合监督网络，实现了传感数据、物理仿真与工艺先验的深度整合。然而，上述研究虽然在特定实验条件下取得了良好效果，但其模型训练和测试通常基于相同或相似的设备配置与工艺参数，隐含假设训练数据与测试数据来自相同分布。

跨工况泛化问题逐渐受到关注。Li 等 [14] 针对 LPBF 过程中换材料导致的模型失效问题，采用数字相机、光电二极管和麦克风三种离轴传感器，分别在 316L 不锈钢和 TC4 钛合金上采集数据，利用充足的源域数据向目标材料的小样本场景进行迁移学习。该工作表明，多模态特征在跨材料迁移中具有可迁移性差异，为少样本工业场景下的模型适应提供了思路。尽管如此，现有方法在面对设备型号、工艺参数和环境光照等综合变化时，其识别性能往往显著下降，难以满足工业现场的实际部署需求。

B. 大模型适配与跨域迁移

预训练视觉大模型为工业缺陷检测的少样本和跨域场景提供了新的技术路径。Gu 等 [5] 提出的 AnomalyGPT 利用大视觉语言模型进行工业异常检测，通过提示学习 (prompt learning) 实现少样本场景下的快速适应，避免了对大量标注数据的依赖。Li 等 [6] 将视觉专家模型与大模型相结合，通过 adapter 机制将传统视觉检测器的优势接入多模态大模型，在保持预训练知识的同时实现特定任务的快速适配。

参数高效微调 (PEFT) 技术为大模型在工业资源受限场景下的部署提供了可行方案。Nguyen 等 [8] 采用 QLoRA 和 Unsloth 技术对视觉语言模型进行资源高效微调，在消费级硬件上实现了自动挖掘机场景的人员检测和天气识别，验证了低资源适配的可行性。Chen 和 Liu [7] 则将主动学习与视觉语言模型相结合，通过迭代选择信息量最大的样本进行标注，在降低标注成本的同时提升了模型在目标域的适应效率。

近期研究开始关注大模型在工业异常检测中的深度适配。Zhao 等 [9] 提出的 OmniAD 框架通过监督微调 (SFT) 与 GRPO 强化学习的联合训练，提升了模型在 MMAD 数据集上的少样本泛化能力。Jiang 等 [10]

构建的 AD-Copilot 通过视觉上下文比较机制，实现了对未见样本的异常判断与定位。然而，上述工作主要聚焦于单一数据集内的准确性提升，对于训练域与测试域存在显著分布差异（如设备型号、工艺参数、材料批次变化）时的跨域泛化能力，现有方法的性能往往显著下降。因此，如何在保持大模型预训练先验的同时，学习对工况变化鲁棒的缺陷表征，成为实现工业现场稳定部署的关键挑战。

III. 未见工况任务形式化

本文首先在问题层面建立未见工况缺陷识别的形式化描述。考虑多模态缺陷检测任务，定义输入空间、标签空间及工况空间如下。

设第 i 个样本具有模态集合 $\mathcal{M}_i = m_1, \dots, m_{K_i}$ ，其中 K_i in $1, 2, 3$ 取决于传感器配置，每个模态 m in $\text{matrmrgb1}, \text{matrmrgb2}, \text{matrmir}$ 对应一种物理观测。样本 i 的工况记为 c_i in $\text{mathcal{C}}$ ，其中 $\mathcal{C}$ 为训练集中出现的工况集合；缺陷标签记为 y_i in $\text{mathcal{Y}}$ ，本文采用三分类设定 $\mathcal{Y} = \text{matrmnormal}, \text{matrmHEW}, \text{matrmLEL}$ 。

训练分布与测试分布的偏移。 设训练集 $\mathcal{D}_{\text{matrmtrain}} = (\mathbf{x}_i, y_i, c_i)_{i=1}^N$ 中所有样本的工况来自集合 $\mathcal{C}_{\text{matrmtrain}}$ 。未见工况测试集 $\mathcal{D}_{\text{matrmtest}}$ 中的样本工况来自 $\mathcal{C}_{\text{matrmtest}}$ ，满足 $\mathcal{C}_{\text{matrmtrain}} \cap \mathcal{C}_{\text{matrmtest}} = \text{varnothing}$ 。这一设定意味着：测试时模型面对的是训练期间从未见过的设备型号、工艺参数或环境配置。

核心问题。 给定 $\mathcal{D}_{\text{matrmtrain}}$ ，学习缺陷分类器 f : $\text{mathcal{X}} \rightarrow \text{mathcal{Y}}$ ，使其在 $\mathcal{D}_{\text{matrmtest}}$ 上保持低泛化误差。直接的经验风险最小化 (ERM) 在此设定下往往失效，因

表 I
主协议与迁移协议的数据统计

数据域	样本数	工况数	Normal	HEW	LEL
data1	289	22	104	86	99
data2	404	22	167	128	109

为模型会利用 c 与 y 在训练集中的虚假相关性（如特定工况下的背景纹理、热场模式），而这些相关性在 $\mathcal{C}_{\text{matrmtest}}$ 中不再成立。

A. 条件级数据划分

本文的实验基于 **data1 official_cv**。该协议不是随机划分图像，而是以 **condition_uid** 为划分单元，从源头上避免同一工况下样本的泄漏。这样得到的评估结果更能反映模型在未见工况上的泛化能力。本文的主任务是三分类缺陷识别，标签为 **normal**、**HEW** 和 **LEL**，其中原始数据中的 **HEV** 被并入 **HEW**。

B. 外部迁移压力测试

data2 transfer_test 不参与模型选择，而作为更困难的外部迁移测试。根据仓库中的分析脚本和结果报告，**data2** 与 **data1** 在模型来源、工艺参数、角色分布与纹理统计上均存在明显差异，因此不能简单视作另一组普通验证集，而应视作更接近真实部署压力的外部迁移测试。

C. 多模态输入与评价目标

仓库当前支持四种输入方式：**rgb_view1**、**rgb_dual**、**ir_only** 和 **triple_view**。为统一表述，本文将输入模态集合写为 $\mathcal{M} \subseteq \{\text{rgb1}, \text{rgb2}, \text{ir}\}$ 。主文所有核心结论均围绕三分类任务展开，因为对于 Qwen 分支而言，三分类比直接二分类更稳定，也更符合本文“识别具体缺陷模式”而不是“粗粒度异常检测”的目标。

表 I 给出了主协议和迁移协议的数据统计。图 1 预留为后续正式绘制的协议示意图。

IV. 方法

A. 多模态数据特征提取

对于样本 i ，记其输入模态集合为 $\mathcal{M}_i = \{m_1, \dots, m_{K_i}\}$ ，其中每个模态对应 **rgb_view1**、**rgb_view2** 或 **ir**。本文将 Qwen2-VL 的视觉编码器 f_{θ_v}




图 1. data1 official_cv 与 data2 transfer_test 协议概览占位图。

作为大模型先验。对于任意模态 $m \in \mathcal{M}_i$ ，编码器输出视觉 token 序列：

$$\mathbf{T}_i^{(m)} = f_{\theta_v}(\mathbf{x}_i^{(m)}) \in \mathbb{R}^{P_i^{(m)} \times d}, \quad (1)$$

其中 $P_i^{(m)}$ 表示空间合并后的 token 数， d 为视觉隐藏维度。与仓库实现一致，本文采用简单平均池化得到单模态表征：

$$\mathbf{z}_i^{(m)} = \frac{1}{P_i^{(m)}} \sum_{p=1}^{P_i^{(m)}} \mathbf{T}_{i,p}^{(m)}. \quad (2)$$

随后，将各模态向量拼接并输入轻量融合头：

$$\mathbf{g}_i = \text{Concat}(\mathbf{z}_i^{(m_1)}, \dots, \mathbf{z}_i^{(m_{K_i})}), \quad (3)$$

$$\tilde{\mathbf{h}}_i = \phi(\text{LN}(\mathbf{g}_i)), \quad \mathbf{r}_i = \frac{\tilde{\mathbf{h}}_i}{\|\tilde{\mathbf{h}}_i\|_2}, \quad (4)$$

其中 $\phi(\cdot)$ 为带有 GELU 和 Dropout 的两层 MLP 融合头。当前官方最优配置使用双 RGB 输入，但这并不意味着 IR 无效；相反，IR-only 的可观结果说明热信息本身具有明显价值，只是当前 Qwen 融合结构尚未把这部分价值完全释放出来。

B. 因果稳定表征约束

记样本 i 的缺陷标签为 y_i ，工况为 c_i 。对每个训练样本，数据集首先构造“同标签、异工况”的正样本池：

$$\Omega_i = \{j \mid j \neq i, y_j = y_i, c_j \neq c_i\}. \quad (5)$$

训练时，若 Ω_i 非空，则随机采样一个正样本索引 $\pi(i)$ 。对 mini-batch $\mathcal{B}$ ，定义

$$\mathcal{B}^+ = \{i \in \mathcal{B} \mid \Omega_i \neq \emptyset\}. \quad (6)$$

因果稳定约束写为

$$\mathcal{L}_{cc} = \frac{1}{|\mathcal{B}^+|} \sum_{i \in \mathcal{B}^+} (1 - \mathbf{r}_i^\top \text{sg}(\mathbf{r}_{\pi(i)})), \quad (7)$$

其中 $\text{sg}(\cdot)$ 表示对正样本分支执行 stop-gradient。这一写法与仓库实现保持一致，即正样本表征以 detached 方式参与约束计算，以降低显存开销并稳定训练。由于 $\mathbf{r}_i$ 已做 ℓ_2 归一化，式 (7) 本质上等价于对跨工况同标签样本的余弦距离进行约束。

这里所谓“因果稳定”是一种操作性假设：在不同工况下，真正应保持稳定的缺陷本体对应的判别依据，而不是工况相关纹理、亮度模式或热背景。通过跨工况同标签对齐，模型被迫减少对这些不稳定因素的依赖，从而更适合未见工况泛化。

C. 大模型轻量适配与真微调对照

本文区分两种适配模式，其可训练参数集合定义为

$$\Theta_{\text{train}} = \begin{cases} \{\theta_f, \theta_c\}, & \text{轻量适配,} \\ \{\theta_v^{\text{last2}}, \theta_m, \theta_f, \theta_c\}, & \text{真微调,} \end{cases} \quad (8)$$

其中 θ_f 为融合头参数， θ_c 为分类器参数， θ_v^{last2} 表示 Qwen2-VL 最后两个视觉 block， θ_m 表示 visual merger。轻量适配是本文的主方法，因为它能最大程度保留大模型视觉先验；真微调则作为诊断性对照，用于回答“在当前小样本场景下，是否继续解冻视觉主干会更好”这一问题。

D. 输出层、优化目标与训练伪代码

最终三分类输出由未归一化融合表示生成：

$$\ell_i = \mathbf{W}_c \tilde{\mathbf{h}}_i + \mathbf{b}_c, \quad \hat{y}_i = \text{softmax}(\ell_i). \quad (9)$$

分类损失采用交叉熵：

$$\mathcal{L}_{\text{cls}} = -\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \log \hat{y}_{i, y_i}, \quad (10)$$

整体训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{cc}, \quad (11)$$

其中官方 causal 配置取 $\lambda = 0.1$ 。训练流程伪代码见表 II。

V. 实验与分析

A. 实验设置

主方法采用 Qwen2-VL-2B-Instruct 视觉塔，输入方式为 rgb_dual，hidden dim 为 512，dropout 为 0.1，batch size 为 4，优化器为 AdamW，学习率为 3×10^{-4} ，




图 2. 本文方法框架占位图。正式版本应体现“多模态特征提取--因果稳定约束--大模型轻量适配/真微调对照--输出判别”四层结构。

表 II
所提方法训练流程伪代码

Require: 训练集 $\mathcal{D}$, 预训练 Qwen 视觉编码器 f_{θ_v} , 适配模式, λ

- 1: 初始化融合头 θ_f 与分类器 θ_c
- 2: 按式 (8) 冻结或解冻相应参数
- 3: **for** 每个 epoch **do**
- 4: **for** 每个 mini-batch $\mathcal{B}$ **do**
- 5: 编码各模态输入并对视觉 token 做平均池化
- 6: 拼接模态向量, 得到 $\tilde{\mathbf{h}}_i$ 、 $\mathbf{r}_i$ 和 $\hat{\mathbf{y}}_i$
- 7: 为每个 anchor 从 Ω_i 中采样跨工况正样本 $\pi(i)$
- 8: 根据式 (7) 计算 $\mathcal{L}_{cc}$
- 9: 计算 $\mathcal{L}_{cls}$ 并最小化式 (11)
- 10: **end for**
- 11: 按验证集 Macro-F1 选择最佳 checkpoint
- 12: **end for**
- 13: 在 data1 official_cv 与 data2 transfer_test 上评估最佳模型

weight decay 为 10^{-4} , 使用 cosine 调度、混合精度训练与 patience 为 2 的 early stopping。因果稳定约束权重取 0.1。真微调对照实验使用 batch size 1、3 个 epoch、patience 为 1, 视觉侧学习率为 2×10^{-6} , 融合头学习率为 5×10^{-5} , 梯度裁剪阈值为 0.5。最强经典基线为 ResNet18 + rgb_dual + MLP-concat。所有源域结果均在 3 个折上汇总。

B. 条件级主协议结果

表 III 给出了 data1 official_cv 三分类主结果。首先, Prompt-Qwen 在该协议上仅取得 0.3914 的 Macro-F1, 说明直接 prompt 适配并不能有效利用大模型先验。其次, 若将同一 Qwen2-VL 视觉先验转化为显式判别式融合框架, 性能可提升到 0.8402。最后, 在此基础上加入因果稳定约束后, Macro-F1 进一步提升到 0.8547, 并超过当前最强经典基线 0.8323。由此可见, 真正有效的不是“简单换成大模型”, 而是“以稳定的判别式方式使用大模型先验”。




图 3. data1 official_cv 三分类主结果占位图。

辅助二分类结果也支持同样结论。Prompt-Qwen 的二分类 Macro-F1 仅为 0.3903, 因果 Qwen 融合分支为 0.4707, 均显著弱于经典最优二分类基线。因此, 本文坚持将三分类作为主任务, 把直接二分类仅作为负结果分析。

C. 多模态有效性分析

表 IV 给出了 Qwen 融合分支的输入消融结果。需要强调的是, 这组结果支持的结论不是“只有双 RGB 有用”, 而是“多模态有效, 但其增益依赖融合方式”。首先, IR-only 仍能达到 0.6270 的 Macro-F1, 说明红外热信息确实包含有意义的缺陷线索。其次, 双 RGB 是当前 Qwen 架构下最稳定的输入形式, 因为两个视角提供了更稳健的几何与纹理互补。最后, 三模态直接拼接没有超过双 RGB, 说明当前问题不在于是否引入 IR, 而在于如何更有效地建模其热特征贡献。

这一判断与迁移基线的表现是相互印证的: 在 data2 上, 经典最优方法反而采用了 triple-view late fusion。这进一步说明 IR 并非无效, 而是其最佳利用方式与模型家族密切相关。

表 III
DATA1 OFFICIAL_CV 三分类主结果

方法家族	具体设置	Accuracy	Balanced Accuracy	Macro-F1
Prompt-Qwen	3-class prompt baseline	0.4809 $\pm$ 0.0602	0.5021 $\pm$ 0.0460	0.3914 $\pm$ 0.0587
Classic	ResNet18 + rgb_dual + MLP-concat	0.8349 $\pm$ 0.0858	0.8412 $\pm$ 0.0846	0.8323 $\pm$ 0.0892
QwenVisFusion	冻结式先验 baseline	0.8383 $\pm$ 0.1009	0.8422 $\pm$ 0.1061	0.8402 $\pm$ 0.1048
QwenVisFusion	冻结式先验 + 因果稳定约束	0.8521 $\pm$ 0.0929	0.8556 $\pm$ 0.0973	0.8547 $\pm$ 0.0955
QwenVisFusion Last2 FT	解冻最后两个视觉 block	0.7850 $\pm$ 0.0378	0.7979 $\pm$ 0.0332	0.7781 $\pm$ 0.0411

表 IV
QWEN 融合分支三分类输入消融

输入方式	Balanced Accuracy	Macro-F1
rgb_view1 baseline	0.7714 $\pm$ 0.0771	0.7419 $\pm$ 0.1203
ir_only baseline	0.6508 $\pm$ 0.0708	0.6270 $\pm$ 0.0878
rgb_dual baseline	0.8422 $\pm$ 0.1061	0.8402 $\pm$ 0.1048
triple_view baseline	0.8169 $\pm$ 0.0659	0.8121 $\pm$ 0.0615
rgb_dual + 因果稳定约束	0.8556 $\pm$ 0.0973	0.8547 $\pm$ 0.0955

表 V
DATA2 TRANSFER_TEST 三分类最佳迁移结果

家族 / 最佳模型	Balanced Accuracy	Macro
Prompt-Qwen / data1_official_cv_3class_baseline	0.4586 $\pm$ 0.0286	0.4073 $\pm$
Classic / triple-view late fusion	0.4973 $\pm$ 0.0954	0.4236 $\pm$
QwenVisFusion / rgb_dual + 因果稳定约束	0.6359 $\pm$ 0.0158	0.6067 $\pm$

D. 因果稳定约束为何有效，真微调为何有害

从数值上看，因果稳定约束带来的提升幅度小于 Prompt-Qwen 到显式融合的性能跃迁，但它恰恰对应本文的核心创新点。在冻结式 Qwen 融合框架已经成立的前提下，因果稳定约束仍将 Macro-F1 从 0.8402 提升到 0.8547，将 balanced accuracy 从 0.8422 提升到 0.8556。这说明，在小样本未见工况场景中，单纯保留大模型先验还不够，还需要通过跨工况同标签对齐来抑制工况诱导的伪相关。

真微调实验则给出了一个重要边界条件。若解冻最后两个视觉 block，则 data1 official_cv 上的 Macro-F1 会从 0.8547 降到 0.7781，在 data2 transfer_test 上则从 0.6067 降到 0.5808。该结果说明，当前问题并不是大模型先验“适配得还不够”，而是激进微调会破坏原有稳定视觉表征，引发对有限样本和工况特征的过拟合。换言之，因果稳定约束的价值在于提升“轻量适配”的质量，而不是为激进真微调兜底。

E. 外部迁移压力测试结果

表 V 展示了 data2 transfer_test 上的最佳三分类迁移结果。Prompt-Qwen 的 Macro-F1 为 0.4073，经典最优迁移基线为 0.4236，而本文方法达到 0.6067。由于 data2 含有更强的复合分布偏移，因此这一优势比单纯的源域提升更有说服力，它表明因果稳定约束不仅改善了源域条件级泛化，也增强了更强外部迁移场景下的识别稳健性。




图 4. data2 transfer_test 最佳模型对比占比图。

迁移结果也进一步补全了本文的多模态叙事。红外信息在增材制造监测中依然具有物理意义和统计价值 [3], [4]。当前 Qwen 最优配置选择双 RGB，主要反映的是现有融合结构和样本规模的约束，而不是 IR 在缺陷识别中没有作用。

VI. 结论

本文围绕一个更贴近工业部署的问题展开研究：在严格条件级划分和更强外部迁移压力下，如何利用大模型先验实现 SLM 多模态缺陷的稳定识别。基于仓库正式实验结果，本文表明直接 Prompt-Qwen 路线并不适合当前小样本未见工况任务。相比之下，将 Qwen2-VL 作为视觉先验编码器，结合显式多模态融合与因果稳定约束，能够在主协议和外部迁移测试上同时取得最优表现。进一步地，真微调实验说明，当前更有效的路径不是继续激进解冻视觉主干，而是保留强先验、通过因果稳定约束提升表示质量。后续工作可进一步探索面向 IR 热特征的更细粒度融合机制，以及比直接解冻更温和的视觉侧 adapter/LoRA 方案。

参考文献

- [1] B. Zhang, Y. Li, and Q. Bai, "Defect formation mechanisms in selective laser melting: A review," *Chinese Journal of Mechanical Engineering*, vol. 30, pp. 515–527, 2017.
- [2] X. Peng, L. Kong, H. An, and G. Dong, "A review of in situ defect detection and monitoring technologies in selective laser melting," *3D Printing and Additive Manufacturing*, vol. 10, no. 3, pp. 438–466, 2023.
- [3] D. Guillen, S. Wahlquist, and A. Ali, "Critical review of LPBF metal print defects detection: Roles of selective sensing technology," *Applied Sciences*, vol. 14, no. 15, p. 6718, 2024.
- [4] P. Wang *et al.*, "Towards intelligent defect detection in metal powder bed fusion: A review of in situ monitoring, data pre-processing, and machine learning," *Materials Science and Engineering: R: Reports*, vol. 167, p. 101112, 2026.
- [5] Z. Gu *et al.*, "AnomalyGPT: Detecting industrial anomalies using large vision-language models," arXiv:2308.15366, 2023.
- [6] Y. Li *et al.*, "Myriad: Large multimodal model by applying vision experts for industrial anomaly detection," arXiv:2310.19070, 2023.
- [7] S. Chen and Y. Liu, "Vision-language model-assisted active learning for high-accuracy defect detection in automotive bushing components," in *Proc. Int. Conf. Embodied Intelligence and Large Models*, 2025, pp. 9–14.
- [8] H. V. Nguyen, H. Park, N. Yoo, and J. Yang, "Resource-efficient fine-tuning of large vision-language models for multimodal perception in autonomous excavators," *Frontiers in Artificial Intelligence*, vol. 8, p. 1681277, 2025.
- [9] S. Zhao *et al.*, "OmniAD: Detect and understand industrial anomaly via multimodal reasoning," arXiv:2505.22039, 2025.
- [10] X. Jiang *et al.*, "AD-Copilot: A vision-language assistant for industrial anomaly detection via visual in-context comparison," arXiv:2603.13779, 2026.
- [11] Q. Wu *et al.*, "In-situ quality intelligent classification of additively manufactured parts using a multi-sensor fusion based melt pool monitoring system," *Additive Manufacturing Frontiers*, vol. 3, no. 3, p. 200153, 2024.
- [12] H. Liu *et al.*, "Inference of highly time-resolved melt pool visual characteristics and spatially-dependent lack-of-fusion defects in laser powder bed fusion using acoustic and thermal emission data," *Additive Manufacturing*, vol. 83, p. 104057, 2024.
- [13] T. Shen *et al.*, "Multi-source information fusion for enhanced in-process quality monitoring of laser powder bed fusion additive manufacturing," *Additive Manufacturing*, vol. 96, p. 104575, 2024.
- [14] J. Li *et al.*, "Transfer learning-based quality monitoring of laser powder bed fusion across materials," *Expert Systems with Applications*, vol. 252, p. 124150, 2024.