

基于大模型先验与因果稳定约束的金属增材制造多模态缺陷识别方法

作者姓名

摘要—金属增材制造在线监测通常同时提供多路传感器数据,但在小样本和未见工况条件下,缺陷识别模型容易依赖工况纹理、热场背景等非稳定捷径特征,导致泛化性能显著下降。本文基于现有代码仓库,建立了以 `condition_uid` 为划分单元的 `data1 official_cv` 条件级主协议,并将 `data2 transfer_test` 视为包含未见模型和未见工艺的外部迁移压力测试。围绕该设定,本文关注的核心问题是:如何在金属增材制造多模态缺陷识别中有效使用大模型先验,并在未见工况下保持稳定识别能力。实验表明,直接采用 Qwen2-VL 进行 prompt 式闭集分类效果有限,在 `data1 official_cv` 三分类上的 Macro-F1 仅为 0.3914。为此,本文提出一种基于 Qwen2-VL 视觉编码器、显式多模态融合头与因果稳定约束的大模型适配框架。该方法将 Qwen2-VL 作为预训练视觉先验,在融合表示空间中对同标签异工况样本施加一致性约束,并以轻量判别头完成小样本适配。实验结果表明,所提方法在 `data1 official_cv` 上取得 0.8547 的 Macro-F1 和 0.8556 的 balanced accuracy,在 `data2 transfer_test` 上取得 0.6067 的 Macro-F1,均优于 prompt-Qwen 和最强经典基线。输入消融进一步说明,RGB view 1、RGB view 2 与 IR 均提供有效缺陷线索,只是当前 Qwen 分支最优实现仍为双 RGB。进一步的真微调实验表明,直接解冻最后两个视觉 block 会导致性能退化,说明在当前小样本工业场景中,保留大模型先验并引入因果稳定约束,比激进端到端微调更有利于未见工况下的鲁棒识别。

Index Terms—选择性激光熔化,缺陷识别,多模态融合,未见工况泛化,外部迁移,大模型先验,因果稳定约束。

I. 引言

金属增材制造通过逐层熔化金属粉末构建复杂几何零件,已广泛应用于航空航天、医疗器械和模具制造等领域。以选择性激光熔化 (Selective Laser Melting, SLM) 为例 [?],该工艺成形涉及熔池动力学、热传导和凝固等复杂物理过程,工艺参数的波动会直接导致气孔、裂纹和几何变形等缺陷 [?],微小的工艺偏差即可显著影响零件的机械性能和服役可靠性。

工业系统通常部署可见光相机与红外热像仪同步监测金属增材制造过程 [?], [?]。可见光成像捕捉熔池

形态和表面纹理,红外热成像反映热输入分布和温度场演化。这种多模态观测提供互补的缺陷表征信息。然而,现有监测方法大多假设训练数据与测试数据来自相同分布。当工艺参数、设备型号或粉末批次变化时,模型识别性能显著下降。

这一失效模式源于深度学习模型对虚假相关性 (spurious correlations) 的过度依赖。模型倾向于利用背景纹理、光照条件或设备噪声等表面统计特征进行预测,而非缺陷本质的因果特征。在金属增材制造多模态监测中,这意味着模型可能将特定工况下的热背景模式误识为缺陷依据,导致在未见工况 (unseen condition) 下失效。如何实现训练工况到未见工况的稳定识别,成为金属增材制造 (特别是 SLM) 缺陷识别的核心问题。

预训练视觉大模型为上述问题提供了可能的解决路径。这些模型通常在海量多模态数据上训练,具备处理异构数据特征输入的能力;其接触到的多样化视觉模式,理论上应有助于提取跨工况稳定的特征。然而,现有实验表明:简单的提示工程 (prompt engineering) 方法在未见工况设定下性能不足。大模型的多模态先验并不能自动转化为对工业缺陷的准确识别,关键在于如何设计适配机制,使其在保持跨工况稳定性的同时,有效融合多源传感器数据中的互补信息。

本文提出一种基于大模型先验与因果稳定约束的未见工况缺陷识别方法。核心思路是将预训练视觉大模型作为跨工况特征提取器,通过显式多模态融合整合可见光与红外热信息,并在融合空间中施加因果一致性约束。该方法采用轻量化的判别式适配机制,在保留大模型预训练先验的同时,学习跨工况不变的缺陷表征。具体而言,"因果稳定"假设认为:与工况相关的纹理、亮度和热背景特征会随工艺条件变化,而缺陷本体的本质特征应当在跨工况时保持稳定。通过对同标签但来自不同工况的样本施加一致性约束,模型被迫减少对不稳定环境因素的依赖,从而学习到从训练工况到未见工况的

稳健映射。

本文的主要贡献可概括为以下三方面：

- 1) 论证了多模态融合在未见工况缺陷识别中的必要性。通过对比单模态与多模态配置在跨工况场景下的性能差异，表明融合可见光与红外信息能够显著提升模型对未见设备、未见工艺参数的适应能力，为工业监测系统的传感器配置提供了实证依据。
- 2) 构建了大模型先验引导的未见工况缺陷识别框架。该框架采用轻量化判别式适配机制，在冻结预训练视觉主干的同时，通过可学习的多模态融合头实现特征整合，兼顾了部署效率与识别精度。实验表明，该框架在跨设备迁移场景中保持了稳定的缺陷检出率，具备较强的工程实用性。
- 3) 提出了因果稳定表征学习机制。通过对同标签但来自不同工况的样本施加一致性约束，迫使模型抑制对背景纹理、热噪声等环境因素的依赖，转而学习缺陷本体的本质特征。这一机制使模型能够从训练工况有效泛化到未见工况，为实现鲁棒的工业视觉监测提供了可行路径。

II. 相关工作

A. 金属增材制造中的多模态缺陷监测

金属增材制造过程的在线监测已成为确保成形质量的关键环节。Zhang 等 [?] 系统综述了选择性激光熔化中的缺陷形成机制，指出工艺参数波动与缺陷产生之间存在密切关联。Peng 等 [?] 进一步总结了缺陷检测与监测技术的进展，表明单一模态难以全面捕捉缺陷特征。现有研究主要沿三个技术路线展开：基于可见光成像的形貌分析、基于红外热成像的温度场监测，以及多传感器数据融合方法 [?], [?].

多传感器信息融合的有效性已在近期研究中得到验证。Wu 等 [?] 采用高速相机、光电二极管和麦克风三种模态对 LPBF 熔池过程进行实时监测，通过改进的 LeNet-5 和加权 Dempster-Shafer 证据理论进行单、双、三传感器融合对比，结果表明三传感器融合显著提升了质量等级识别准确率。这一工作确立了多模态互补在缺陷识别中的价值。但多传感器方案往往伴随部署成本的攀升，这促使研究者探索更具成本效益的替代方案。Liu 等 [?] 利用声发射和热辐射信号推断高时间分辨率的熔池视觉特征，将昂贵的 1.0 ms 高速成像替换为更易部

署的声学-热辐射组合，为工业现场的传感器配置提供了可行路径。

传感器配置的多样化也推动了融合策略的演进。Shen 等 [?] 将逐层熔池红外图像、熔道顶视照片、数值模拟图、工艺参数和熔池截面形貌特征参数共同输入模型，提出残差物理融合监督网络，实现了传感数据、物理仿真与工艺先验的深度整合。Li 等 [?] 则针对换材料导致的模型失效问题，利用充足的源域数据向目标材料的小样本场景进行迁移学习，揭示了多模态特征在跨材料迁移中的可迁移性差异。

上述研究尽管在特定实验条件下取得了良好效果，但其模型训练和测试通常基于相同或相似的设备配置与工艺参数，隐含假设训练数据与测试数据来自相同分布。当面对设备型号、工艺参数和环境光照等综合变化时，现有方法的识别性能往往显著下降，难以满足工业现场的实际部署需求。

B. 大模型适配与跨域迁移

预训练视觉大模型为工业缺陷检测的少样本和跨域场景提供了新的技术路径。Gu 等 [?] 提出的 AnomalyGPT 利用大视觉语言模型进行工业异常检测，通过提示学习 (prompt learning) 实现少样本场景下的快速适应，避免了对大量标注数据的依赖。Li 等 [?] 则将视觉专家模型与大模型相结合，通过 adapter 机制将传统视觉检测器的优势接入多模态大模型，在保持预训练知识的同时实现特定任务的快速适配。上述工作展示了利用大模型先验进行工业检测的可行性，但如何高效微调以适配资源受限场景仍是关键问题。

参数高效微调 (PEFT) 技术为此提供了可行方案。Nguyen 等 [?] 采用 QLoRA 和 Unsloth 技术对视觉语言模型进行资源高效微调，在消费级硬件上实现了自动挖掘机场景的人员检测和天气识别，验证了低资源适配的可行性。Chen 和 Liu [?] 进一步将主动学习与视觉语言模型相结合，通过迭代选择信息量最大的样本进行标注，在降低标注成本的同时提升了模型在目标域的适应效率。这些研究表明，在工业场景中部署大模型无需全参数微调，轻量适配即可实现任务特化。

近期研究开始探索更深层次的适配策略。Zhao 等 [?] 提出的 OmniAD 框架通过监督微调 (SFT) 与 GRPO 强化学习的联合训练，提升了模型在 MMAD 数据集上的少样本泛化能力。Jiang 等 [?] 构建的 AD-Copilot 通过视觉上下文比较机制，实现了对未见样本的异常判断

与定位。然而，上述工作主要聚焦于单一数据集内的准确性提升，对于训练域与测试域存在显著分布差异（如设备型号、工艺参数、材料批次变化）时的跨域泛化能力，现有方法的性能往往显著下降。因此，如何在保持大模型预训练先验的同时，学习对工况变化鲁棒的缺陷表征，成为实现工业现场稳定部署的关键挑战。

III. 未见工况任务形式化

本节对金属增材制造缺陷识别中的未见工况泛化问题进行形式化描述。考虑多模态监测场景，设样本 i 具有模态集合 $\mathcal{M}_i = \{1, \dots, K_i\}$ ，其中 K_i 为模态数量。每个模态 $k \in \mathcal{M}_i$ 对应一种物理传感器观测 $\mathbf{x}_i^{(k)} \in \mathbb{R}^{H \times W \times C}$ ，缺陷标签记为 $y_i \in \mathcal{Y}$ ，工况标识记为 $c_i \in \mathcal{C}$ 。

未见工况泛化的核心特征在于训练分布与测试分布的偏移。具体而言，训练集 $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_i, y_i, c_i)\}_{i=1}^N$ 中的样本工况来自集合 $\mathcal{C}_{\text{train}}$ ，而测试集 $\mathcal{D}_{\text{test}}$ 中的样本工况来自 $\mathcal{C}_{\text{test}}$ ，两者满足 $\mathcal{C}_{\text{train}} \cap \mathcal{C}_{\text{test}} = \emptyset$ 。该设定意味着模型在测试阶段面对的是训练期间从未见过的工艺参数、打印任务或材料类型。

在此设定下，学习目标是基于 $\mathcal{D}_{\text{train}}$ 训练分类器 $f: \mathcal{X} \times \mathcal{M} \rightarrow \mathcal{Y}$ ，使其在 $\mathcal{D}_{\text{test}}$ 上保持低泛化误差。然而，直接经验风险最小化（ERM）在此往往失效。模型倾向于利用训练集中工况 c 与标签 y 的统计相关性（如特定工况下的背景纹理、热场模式）进行预测，而这些相关性在未见工况 $\mathcal{C}_{\text{test}}$ 中不再成立，导致跨域性能显著退化。

解决该问题需要克服三个关键挑战。其一，如何有效融合多源异构传感器数据以提取互补的缺陷表征；其二，如何学习对工况变化鲁棒的稳定特征，抑制对背景纹理等非本质因素的依赖；其三，如何在有限标注数据条件下充分利用预训练大模型的跨域先验知识。后续章节将围绕这三个挑战依次展开。

IV. 提出方法

针对未见工况金属增材制造缺陷识别问题，本文提出一种基于大模型视觉先验与因果一致性约束的轻量适配框架。该框架的核心思想在于：利用预训练视觉大模型的跨域泛化能力提取多模态特征，在融合表征空间中施加跨工况一致性约束，通过轻量判别头实现小样本条件下的稳定适配。框架整体架构如图 ?? 所示。

形式化地，给定训练集 $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_i, y_i, c_i)\}_{i=1}^N$ ，其中 $\mathbf{x}_i$ 为多模态输入， $y_i \in \mathcal{Y}$ 为缺陷标签， $c_i \in \mathcal{C}_{\text{train}}$ 为工况标识。框架包含三个核心组件：

- 1) **多模态特征提取器**：基于 Qwen2-VL 视觉编码器 f_{θ_v} ，将多源传感器数据映射至语义表征空间；
- 2) **因果一致性表征融合**：通过跨工况对比约束，学习对工况变化鲁棒的缺陷表征；
- 3) **大模型先验的判别式适配**：冻结视觉主干，仅训练轻量融合头与分类层，在保留预训练先验的同时实现任务特化。

以下三节依次详述各组件的数学表述与实现细节。

A. 多模态特征提取器

设样本 i 的输入为 K_i 个模态的集合 $\mathcal{M}_i = \{m_1, \dots, m_{K_i}\}$ ，其中每个模态 m_k 对应传感器采集的原始数据 $\mathbf{x}_i^{(m_k)} \in \mathbb{R}^{H \times W \times C}$ 。本文采用 Qwen2-VL 的视觉编码器 $f_{\theta_v}: \mathbb{R}^{H \times W \times C} \rightarrow \mathbb{R}^{P \times d}$ 作为特征提取器，该编码器基于 Vision Transformer 架构，在海量多模态数据上预训练，具备跨域视觉先验。

对于任意模态 $m \in \mathcal{M}_i$ ，编码器首先通过 patch embedding 层将输入划分为空间网格，经 L 层 Transformer 处理后输出视觉 token 序列：

$$\mathbf{T}_i^{(m)} = f_{\theta_v}(\mathbf{x}_i^{(m)}; \theta_v) \in \mathbb{R}^{P_i^{(m)} \times d}, \quad (1)$$

其中 $P_i^{(m)}$ 为空间合并后的 token 数量， d 为隐藏层维度（Qwen2-VL-2B 中 $d = 1280$ ）。 $\mathbf{T}_i^{(m)} = [\mathbf{t}_{i,1}^{(m)}, \dots, \mathbf{t}_{i,P_i^{(m)}}^{(m)}]^\top$ 可视为该模态在空间各位置的局部语义描述子集合。

为获得模态级全局表征，采用平均池化聚合空间信息：

$$\mathbf{z}_i^{(m)} = \frac{1}{P_i^{(m)}} \sum_{p=1}^{P_i^{(m)}} \mathbf{t}_{i,p}^{(m)} \in \mathbb{R}^d. \quad (2)$$

该操作假设缺陷相关的语义信息在空间上呈分布特性，平均聚合可获得对模态观测的整体语义概括。视觉编码器参数 θ_v 在训练过程中保持冻结，完全依赖预训练获得的跨域视觉先验。这一设计的理论依据在于：Qwen2-VL 在大规模多样化视觉数据上学习到的特征具有跨域稳定性，可直接迁移至金属增材制造缺陷检测任务。

B. 因果一致性表征融合

获得各模态表征 $\{\mathbf{z}_i^{(m)}\}_{m \in \mathcal{M}_i}$ 后，需将其融合为统一的判别表征，并施加跨工况一致性约束。

多模态融合。采用拼接-变换范式，首先将各模态表征拼接：

$$\mathbf{g}_i = \text{Concat}(\mathbf{z}_i^{(m_1)}, \dots, \mathbf{z}_i^{(m_{K_i})}) \in \mathbb{R}^{K_i d}, \quad (3)$$




图 1. 本文提出的未见工况缺陷识别框架。该框架包含三个核心组件：多模态特征提取器、因果一致性表征融合模块、以及大模型先验的判别式适配模块。

随后通过融合头进行非线性变换：

$$\tilde{\mathbf{h}}_i = \phi_{\theta_f}(\text{LN}(\mathbf{g}_i)) \in \mathbb{R}^{d_h}, \quad (4)$$

其中 ϕ_{θ_f} 为含 GELU 与 Dropout 的两层 MLP, $d_h = 512$ 。执行 ℓ_2 归一化：

$$\mathbf{r}_i = \frac{\tilde{\mathbf{h}}_i}{\|\tilde{\mathbf{h}}_i\|_2} \in \mathcal{S}^{d_h-1}. \quad (5)$$

跨工况正样本池。对样本 i ，定义“同标签、异工况”正样本池：

$$\Omega_i = \{j \mid j \neq i, y_j = y_i, c_j \neq c_i\}. \quad (6)$$

因果一致性损失。在 mini-batch $\mathcal{B}$ 中，定义有效锚点集 $\mathcal{B}^+ = \{i \in \mathcal{B} \mid \Omega_i \neq \emptyset\}$ 。对每个 $i \in \mathcal{B}^+$ ，从 Ω_i 采样正样本 $\pi(i)$ 。损失函数为：

$$\mathcal{L}_{cc} = \frac{1}{|\mathcal{B}^+|} \sum_{i \in \mathcal{B}^+} (1 - \mathbf{r}_i^\top \text{sg}(\mathbf{r}_{\pi(i)})), \quad (7)$$

其中 $\text{sg}(\cdot)$ 为 stop-gradient 算子。由于 $\mathbf{r}_i, \mathbf{r}_{\pi(i)} \in \mathcal{S}^{d_h-1}$ ，有 $\mathbf{r}_i^\top \mathbf{r}_{\pi(i)} = \cos \theta_{i,\pi(i)}$ ，因此：

$$\mathcal{L}_{cc} = \frac{2}{|\mathcal{B}^+|} \sum_{i \in \mathcal{B}^+} \sin^2 \frac{\theta_{i,\pi(i)}}{2}, \quad (8)$$

即最小化跨工况同标签样本间的弦距离。

操作性诠释。上述约束体现“因果稳定”假设：与工况相关的纹理、亮度和热背景属于不稳定因素，而缺陷本体的本质特征应在跨工况时保持稳定。通过强制同标签异工况样本的表征对齐，模型被迫学习对未见工况鲁棒的缺陷表征。

C. 大模型先验的判别式适配

在获得因果一致性约束的融合表征后，需通过判别式适配完成缺陷分类任务。本节阐述分类器的数学表述、两种适配模式的形式化定义，以及整体优化目标。

判别式分类器。基于融合表示 $\tilde{\mathbf{h}}_i$ ，通过线性分类器生成类别 logits：

$$\boldsymbol{\ell}_i = \mathbf{W}_c \tilde{\mathbf{h}}_i + \mathbf{b}_c \in \mathbb{R}^{|\mathcal{Y}|}, \quad (9)$$

其中 $\mathbf{W}_c \in \mathbb{R}^{|\mathcal{Y}| \times d_h}$ 为权重矩阵， $\mathbf{b}_c \in \mathbb{R}^{|\mathcal{Y}|}$ 为偏置向量。类别概率分布由 softmax 函数获得：

$$\hat{\mathbf{y}}_i = \text{softmax}(\boldsymbol{\ell}_i) = \left[\frac{e^{\ell_{i,1}}}{\sum_k e^{\ell_{i,k}}}, \dots, \frac{e^{\ell_{i,|\mathcal{Y}|}}}{\sum_k e^{\ell_{i,k}}} \right]^\top. \quad (10)$$

分类任务采用交叉熵损失：

$$\mathcal{L}_{cls} = -\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \log \hat{y}_{i,y_i}, \quad (11)$$

其中 $\hat{y}_{i,y_i}$ 表示样本 i 对应真实标签的预测概率。

适配模式的形式化定义。本文区分两种大模型适配策略，其可训练参数集合定义为：

$$\Theta_{\text{train}} = \begin{cases} \{\theta_f, \theta_c\}, & \text{轻量适配,} \\ \{\theta_v^{\text{last2}}, \theta_m, \theta_f, \theta_c\}, & \text{真微调,} \end{cases} \quad (12)$$

其中 θ_f 为融合头参数, $\theta_c = (\mathbf{W}_c, \mathbf{b}_c)$ 为分类器参数, θ_v^{last2} 表示 Qwen2-VL 最后两个视觉 block 的参数, θ_m 为视觉 merger 参数。

轻量适配模式下, 视觉编码器参数 θ_v 保持冻结, 仅训练融合头与分类器。该策略的理论依据在于: 预训练视觉大模型已在海量多样化数据上学习到跨域稳定的底层特征表示, 冻结操作可防止小样本场景下的过拟合, 保留其跨工况泛化能力。真微调模式则额外解冻最后两个视觉 block, 允许高层视觉特征随任务调整, 作为诊断性对照以验证“保留预训练先验优于激进微调”的假设。

整体优化目标。联合优化分类损失与因果一致性损失:

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{cc}}, \quad (13)$$

其中 λ 为平衡系数 (本文取 $\lambda = 0.1$)。该目标函数体现本文核心思想: 在保留大模型视觉先验的同时, 通过因果一致性约束学习跨工况稳定的缺陷表征, 实现轻量且鲁棒的未见工况适配。

训练流程遵循标准的 mini-batch 梯度下降。对每个 batch, 首先计算各模态的视觉表征并完成融合, 随后采样跨工况正样本计算 $\mathcal{L}_{\text{cc}}$, 最后联合优化总损失 $\mathcal{L}$ 。算法伪代码实现参见工程代码仓库。

V. 实验与分析

A. 实验设置

主方法采用 Qwen2-VL-2B-Instruct 视觉塔, 输入方式为 `rgb_dual`, hidden dim 为 512, dropout 为 0.1, batch size 为 4, 优化器为 AdamW, 学习率为 3×10^{-4} , weight decay 为 10^{-4} , 使用 cosine 调度、混合精度训练与 patience 为 2 的 early stopping。因果稳定约束权重取 0.1。真微调对照实验使用 batch size 1、3 个 epoch、patience 为 1, 视觉侧学习率为 2×10^{-6} , 融合头学习率为 5×10^{-5} , 梯度裁剪阈值为 0.5。最强经典基线为 ResNet18 + `rgb_dual` + MLP-concat。所有源域结果均在 3 个折上汇总。

B. 条件级主协议结果

表 ?? 给出了 `data1 official_cv` 三分类主结果。首先, Prompt-Qwen 在该协议上仅取得 0.3914 的 Macro-F1, 说明直接 prompt 适配并不能有效利用大模型先验。其次, 若将同一 Qwen2-VL 视觉先验转化为显式判别式融合框架, 性能可提升到 0.8402。最后, 在此基础上加




图 2. `data1 official_cv` 三分类主结果占比图。

入因果稳定约束后, Macro-F1 进一步提升到 0.8547, 并超过当前最强经典基线 0.8323。由此可见, 真正有效的不是“简单换成大模型”, 而是“以稳定的判别式方式使用大模型先验”。

辅助二分类结果也支持同样结论。Prompt-Qwen 的二分类 Macro-F1 仅为 0.3903, 因果 Qwen 融合分支为 0.4707, 均显著弱于经典最优二分类基线。因此, 本文坚持将三分类作为主任务, 把直接二分类仅作为负结果分析。

C. 多模态有效性分析

表 ?? 给出了 Qwen 融合分支的输入消融结果。需要强调的是, 这组结果支持的结论不是“只有双 RGB 有用”, 而是“多模态有效, 但其增益依赖融合方式”。首先, IR-only 仍能达到 0.6270 的 Macro-F1, 说明红外热信息确实包含有意义的缺陷线索。其次, 双 RGB 是当前 Qwen 架构下最稳定的输入形式, 因为两个视角提供了更稳健的几何与纹理互补。最后, 三模态直接拼接没有超过双 RGB, 说明当前问题不在于是否引入 IR, 而在于如何更有效地建模其热特征贡献。

这一判断与迁移基线的表现是相互印证的: 在 `data2` 上, 经典最优方法反而采用了 `triple-view late fusion`。这进一步说明 IR 并非无效, 而是其最佳利用方式与模型家族密切相关。

D. 因果稳定约束为何有效, 真微调为何有害

从数值上看, 因果稳定约束带来的提升幅度小于 Prompt-Qwen 到显式融合的性能跃迁, 但它恰恰对应本文的核心创新点。在冻结式 Qwen 融合框架已经成立的前提下, 因果稳定约束仍将 Macro-F1 从 0.8402 提升到 0.8547, 将 `balanced accuracy` 从 0.8422 提升到 0.8556。这说明, 在小样本未见工况场景中, 单纯保留大模型先

表 I
DATA1 OFFICIAL_CV 三分类主结果

方法家族	具体设置	Accuracy	Balanced Accuracy	Macro-F1
Prompt-Qwen	3-class prompt baseline	0.4809 $\pm$ 0.0602	0.5021 $\pm$ 0.0460	0.3914 $\pm$ 0.0587
Classic	ResNet18 + rgb_dual + MLP-concat	0.8349 $\pm$ 0.0858	0.8412 $\pm$ 0.0846	0.8323 $\pm$ 0.0892
QwenVisFusion	冻结式先验 baseline	0.8383 $\pm$ 0.1009	0.8422 $\pm$ 0.1061	0.8402 $\pm$ 0.1048
QwenVisFusion	冻结式先验 + 因果稳定约束	0.8521 $\pm$ 0.0929	0.8556 $\pm$ 0.0973	0.8547 $\pm$ 0.0955
QwenVisFusion Last2 FT	解冻最后两个视觉 block	0.7850 $\pm$ 0.0378	0.7979 $\pm$ 0.0332	0.7781 $\pm$ 0.0411

表 II
QWEN 融合分支三分类输入消融

输入方式	Balanced Accuracy	Macro-F1
rgb_view1 baseline	0.7714 $\pm$ 0.0771	0.7419 $\pm$ 0.1203
ir_only baseline	0.6508 $\pm$ 0.0708	0.6270 $\pm$ 0.0878
rgb_dual baseline	0.8422 $\pm$ 0.1061	0.8402 $\pm$ 0.1048
triple_view baseline	0.8169 $\pm$ 0.0659	0.8121 $\pm$ 0.0615
rgb_dual + 因果稳定约束	0.8556 $\pm$ 0.0973	0.8547 $\pm$ 0.0955

表 III
DATA2 TRANSFER_TEST 三分类最佳迁移结果

家族 / 最佳模型	Balanced Accuracy	Macro-F1
Prompt-Qwen / data1_official_cv_3class_baseline	0.4586 $\pm$ 0.0286	0.4236 $\pm$ 0.0110
Classic / triple-view late fusion	0.4973 $\pm$ 0.0954	0.4336 $\pm$ 0.0110
QwenVisFusion / rgb_dual + 因果稳定约束	0.6359 $\pm$ 0.0158	0.6067 $\pm$ 0.0351




图 3. data2 transfer_test 最佳模型对比占比图。

验还不够，还需要通过跨工况同标签对齐来抑制工况诱导的伪相关。

真微调实验则给出了一个重要边界条件。若解冻最后两个视觉 block，则 data1 official_cv 上的 Macro-F1 会从 0.8547 降到 0.7781，在 data2 transfer_test 上则从 0.6067 降到 0.5808。该结果说明，当前问题并不是大模型先验“适配得还不够”，而是激进微调会破坏原有稳定视觉表征，引发对有限样本和工况特征的过拟合。换言之，因果稳定约束的价值在于提升“轻量适配”的质量，而不是为激进真微调兜底。

E. 外部迁移压力测试结果

表 ?? 展示了 data2 transfer_test 上的最佳三分类迁移结果。Prompt-Qwen 的 Macro-F1 为 0.4073，经典最优迁移基线为 0.4236，而本文方法达到 0.6067。由于 data2 含有更强的复合分布偏移，因此这一优势比单纯的源域提升更有说服力，它表明因果稳定约束不仅改善了源域条件级泛化，也增强了更强外部迁移场景下的识别稳健性。

迁移结果也进一步补全了本文的多模态叙事。红外信息在增材制造监测中依然具有物理意义和统计价值

[2], [21] 当前 Qwen 最优配置选择双 RGB，主要反映的是现有融合结构和样本规模的约束，而不是 IR 在缺陷识别中没有作用。

VI. 结论

本文围绕一个更贴近工业部署的问题展开研究。在严格条件级划分和更强外部迁移压力下，如何利用大模型先验实现金属增材制造多模态缺陷的稳定识别，是本文关注的核心。基于仓库正式实验结果，本文表明直接 Prompt-Qwen 路线并不适合当前小样本未见工况任务。相比之下，将 Qwen2-VL 作为视觉先验编码器，结合显式多模态融合与因果稳定约束，能够在主协议和外部迁移测试上同时取得最优表现。进一步地，真微调实验说明，当前更有效的路径不是继续激进解冻视觉主干，而是保留强先验、通过因果稳定约束提升表示质量。后续工作可进一步探索面向 IR 热特征的更细粒度融合机制，以及比直接解冻更温和的视觉侧 adapter/LoRA 方案。

参考文献

- [1] B. Zhang, Y. Li, and Q. Bai, “Defect formation mechanisms in selective laser melting: A review,” *Chinese Journal of Mechanical Engineering*, vol. 30, pp. 515–527, 2017.
- [2] X. Peng, L. Kong, H. An, and G. Dong, “A review of in situ defect detection and monitoring technologies in selective laser melting,” *3D Printing and Additive Manufacturing*, vol. 10, no. 3, pp. 438–466, 2023.
- [3] D. Guillen, S. Wahlquist, and A. Ali, “Critical review of LPBF metal print defects detection: Roles of selective sensing technology,” *Applied Sciences*, vol. 14, no. 15, p. 6718, 2024.

- [4] P. Wang *et al.*, “Towards intelligent defect detection in metal powder bed fusion: A review of in situ monitoring, data pre-processing, and machine learning,” *Materials Science and Engineering: R: Reports*, vol. 167, p. 101112, 2026.
- [5] Z. Gu *et al.*, “AnomalyGPT: Detecting industrial anomalies using large vision-language models,” arXiv:2308.15366, 2023.
- [6] Y. Li *et al.*, “Myriad: Large multimodal model by applying vision experts for industrial anomaly detection,” arXiv:2310.19070, 2023.
- [7] S. Chen and Y. Liu, “Vision-language model-assisted active learning for high-accuracy defect detection in automotive bushing components,” in *Proc. Int. Conf. Embodied Intelligence and Large Models*, 2025, pp. 9–14.
- [8] H. V. Nguyen, H. Park, N. Yoo, and J. Yang, “Resource-efficient fine-tuning of large vision-language models for multimodal perception in autonomous excavators,” *Frontiers in Artificial Intelligence*, vol. 8, p. 1681277, 2025.
- [9] S. Zhao *et al.*, “OmniAD: Detect and understand industrial anomaly via multimodal reasoning,” arXiv:2505.22039, 2025.
- [10] X. Jiang *et al.*, “AD-Copilot: A vision-language assistant for industrial anomaly detection via visual in-context comparison,” arXiv:2603.13779, 2026.
- [11] Q. Wu *et al.*, “In-situ quality intelligent classification of additively manufactured parts using a multi-sensor fusion based melt pool monitoring system,” *Additive Manufacturing Frontiers*, vol. 3, no. 3, p. 200153, 2024.
- [12] H. Liu *et al.*, “Inference of highly time-resolved melt pool visual characteristics and spatially-dependent lack-of-fusion defects in laser powder bed fusion using acoustic and thermal emission data,” *Additive Manufacturing*, vol. 83, p. 104057, 2024.
- [13] T. Shen *et al.*, “Multi-source information fusion for enhanced in-process quality monitoring of laser powder bed fusion additive manufacturing,” *Additive Manufacturing*, vol. 96, p. 104575, 2024.
- [14] J. Li *et al.*, “Transfer learning-based quality monitoring of laser powder bed fusion across materials,” *Expert Systems with Applications*, vol. 252, p. 124150, 2024.